

一、簡介

本作業實作條件式去噪擴散機率模型 (Conditional DDPM)，依多標籤條件生成 64×64 i-CLEVR 合成影像。

二、實作細節

(1) 條件表示：每張圖最多 3 個物體，各自轉為獨立 token id (24 類 + 1 個 padding token)，經 Token Embedding + 位置 Embedding 後形成 (B, 3, 256) 的條件 token 序列，而非單一 multi-hot 向量。此設計讓模型能分別處理每個物體的條件。

(2) Cross-Attention：在 U-Net 16×16 與 8×8 解析度層加入 Cross-Attention block，影像每個空間位置作為 Query，條件 token 序列作為 Key/Value，讓模型學習「畫面哪個區域該對應哪個物體」的空間綁定關係，解決原版 multi-hot 條件造成的屬性混淆問題 (顏色與形狀配對錯誤)。

(3) U-Net 架構：base_ch=128，4 層編解碼器，Self-Attention + Cross-Attention 雙重注意力機制，全層 skip connection。

(4) 擴散訓練：T=1000 步線性 β schedule ($1e-4 \rightarrow 0.02$)， ϵ -預測 (MSE loss)。

(5) 訓練設定：全量 18009 張；batch=64；AdamW lr= $2e-4$ ；CosineAnnealingLR；150 epochs；EMA decay=0.9999；10% 機率訓練無條件分支 (CFG)。

(6) 推論：DDIM (S=100 步， $\eta=0.0$ ，cfg_scale=0.0)。

(7) 參考：Ho et al., DDPM (NeurIPS 2020)；Rombach et al., Stable Diffusion cross-attention conditioning (CVPR 2022)；Song et al., DDIM (ICLR 2021)。

三、實驗結果

- test.json 分類準確率：0.9167
- new_test.json 分類準確率：0.9643
- 去噪展示標籤：['red sphere', 'cyan cylinder', 'cyan cube']

四、討論

原版用單一 multi-hot 向量表示所有物體條件，單物體準確率達 100%，但多物體時掉到 66~79%，逐筆分析顯示錯誤多為「顏色形狀互相配對錯誤」(屬性綁定混淆)，而非顏色或形狀本身學不會。本版改用獨立 token 序列 + Cross-Attention，讓模型能個別查詢每個物體的條件，顯著改善多物體場景下的屬性綁定準確度。

圖1：test.json 合成影像網格（8欄×4列）




圖2：new_test.json 合成影像網格 (8欄×4列)



圖3：去噪過程 (red sphere, cyan cylinder, cyan cube)

